

Leveraging Probabilistic Confidence Signals for Reasoning Correctness Prediction in the Cosmos T1 Model

(Olasılıksal Güven Sinyalleri Kullanılarak Cosmos T1 Modelinde Akıl Yürütme Doğruluğunun Kestirimi)

İrem Selen
Computer Engineering
Yıldız Technical University
İstanbul, Türkiye
irem.selen@std.yildiz.edu.tr

Mehmet Fatih Amasyalı
Computer Engineering
Yıldız Technical University
İstanbul, Türkiye
amasyali@yildiz.edu.tr

Abstract—This study analyzes the mathematical reasoning processes of the Turkish-Gemma-9b-T1 model (Cosmos T1) on the GSM8K-TR dataset through token-level confidence signals derived from the top1-top2 probability gap. Fifty features capturing time-series dynamics are extracted from each response sequence and used for correct/incorrect classification via machine learning and deep learning methods. Experiments are conducted on 1,200 questions with 5-fold cross-validation, achieving a best result of 0.70 AUC with Logistic Regression. Analysis reveals that early-phase confidence features (first_10_mean, first_50_mean) constitute the strongest positive predictive signal, while response length emerges as an equally strong negative indicator, with longer responses showing a markedly higher likelihood of being incorrect. These findings suggest that the confidence profile of only the initial tokens in an LLM’s generation process carries an important signal for predicting final answer correctness.

Index Terms—Computational Semantics, ML, Cosmos, GSM8K, Turkish-Gemma-9b-T1.

Özet — Bu çalışma, Turkish-Gemma-9b-T1 modelinin (Cosmos T1) GSM8K-TR veri seti üzerindeki matematiksel akıl yürütme süreçlerini token bazlı güven sinyalleri (top1-top2 olasılık farkı) aracılığıyla analiz etmektedir. Her cevap dizisinden zaman serisi dinamiklerini kapsayan 50 özellik çıkarılmış; bu özellikler makine öğrenmesi ve derin öğrenme yöntemleriyle doğru/yanlış sınıflandırması için kullanılmıştır. Deneyler 1200 soru üzerinde 5-katlı çapraz doğrulama ile gerçekleştirilmiş; en iyi sonuç Lojistik Regresyon ile 0.70 AUC olarak elde edilmiştir. Analizler, erken dönem güven özelliklerinin doğruluğu tahmin etmede en güçlü sinyal kaynağı olduğunu; cevap uzunluğunun ise eşit güçte en belirleyici negatif sinyal olduğunu ortaya koymaktadır. Bu bulgular, bir LLM’in üretim sürecinin yalnızca ilk tokenlarındaki güven profilinin, nihai cevabın doğruluğunu kestirmek için önemli bir sinyal taşıdığına işaret etmektedir.

I. GİRİŞ

Büyük Dil Modelleri, adım adım akıl yürütme (Chain-of-Thought) gerektiren matematiksel ve mantıksal problemlerde önemli başarılar sergileseler de, bu modellerin karar

süreçleri hâlâ büyük oranda birer kara kutu niteliğindedir. Özellikle modelin ürettiği cevabın doğruluğundan ne kadar emin olduğunu yansıtan güven skorları, modelin halüsinasyona uğrayıp uğramadığını veya mantıksal bir hataya düşüp düşmediğini anlamak için kritik sinyal kaynaklarıdır.

Literatürdeki çalışmaların büyük çoğunluğu İngilizce ağırlıklı veri setlerine ve genel amaçlı modellere odaklanırken, Türkçe modellerin güven dinamikleriyle ilgili çalışmalar sınırlı sayıdadır. Modelin cevap üretirken sergilediği kararsızlık anları, matematiksel problemlerde doğru sonuca ulaşım sağlayamayacağının en güçlü öncüllerinden biri olduğundan bu alandaki çalışmaları arttırmak önemlidir [1].

Bu çalışma, GSM8K-TR veri seti üzerinde [2] Turkish-Gemma-9b-T1 modelinin akıl yürütme süreçlerini inceleyerek, token bazlı güven sinyallerinden (top1-top2 olasılık farkı) nasıl yüksek ayırt ediciliğe sahip öznitelikler türetilbileceğini göstermektedir. Geleneksel yaklaşımların aksine, güven skorlarını tekil bir özet değer olarak değil; zaman serisi dinamiklerini (trendler, çöküşler, istikrar) kapsayan çok boyutlu bir ”profil” olarak ele alıyoruz. Çalışmamızda; dip analizi, entropi yörüngeleri, otokorelasyon ve istatistiksel dağılım şekli gibi 50 farklı öznitelik türetilerek, geleneksel makine öğrenmesi ve derin öğrenme algoritmaları ile modelin ”doğru” ve ”yanlış” cevaplarını tahmin etme kapasitesi test edilmiştir.

Bu araştırma, bir LLM’in üretim süreci boyunca yaşadığı mantıksal kırılmaların ve kararsızlıkların, nihai sonucun güvenilirliğini kestirmede ne kadar etkili olduğunu kanıtlamayı ve Türkçe dilinde akıl yürütme güvenilirliğini ölçmek için özgün bir metodoloji sunmayı amaçlamaktadır.

Çalışmada kullanılan tüm veri setleri (fold verileri ve csv dosyaları dahil) ve kod dosyaları açık kaynaklı olarak paylaşılmıştır.¹

¹Proje kodlarına ve veri setlerine şu adresten erişilebilir: <https://github.com/ramrems/Cosmos-T1-Reasoning-Analysis>

II. İLGİLİ ÇALIŞMALAR

Grünefeld ve arkadaşları tarafından yürütülen "Tracing Uncertainty in Language Model Reasoning" başlıklı benzer çalışmada GSM8K veri seti üzerinde token bazlı belirsizlik dizilimlerini incelenmiştir. Her bir üretim dizisinin (trace) başındaki, ortasındaki ve sonundaki entropi/belirsizlik ortalamaları, eğimi ve doğrusallığı gibi özelliklerden oluşan 30 boyutlu bir "Trace Profile" (İz Profili) çıkartılmıştır. Bu istatistikler Lojistik Regresyon ve Gradient Boosting algoritmalarına verilerek, sadece cümlelerin ilk birkaç yüz tokenine bakılarak final cevabın doğru mu yanlış mı olacağı 0.807 AUROC skoru ile tahmin edilebilmiştir. [3]

Plaut ve arkadaşları tarafından yürütülen "Probabilities of Chat LLMs Are Miscalibrated but Still Predict Correctness on Multiple-Choice Q&A" başlıklı diğer bir kapsamlı çalışmada ise, 15 farklı büyük dil modelinin çoktan seçmeli soru-cevap görevlerindeki olasılık ve güven çıktıları incelenmiştir. Araştırmacılar, chat amacıyla ince ayar yapılmış modellerin ürettiği olasılıkların genellikle hatalı kalibre edilmiş (aşırı özgüvenli) olduğunu, ancak bu durumun modelin kendi cevabının doğruluğunu tahmin etme yeteneğini ortadan kaldırmadığını göstermiştir. Çalışmada sadece en yüksek olasılık değeri değil; aynı zamanda tahmine yönelik en yüksek iki olasılık ve logit değeri arasındaki fark da bir belirsizlik sinyali olarak analiz edilmiştir. Sonuçlar, hesaplanan bu olasılık farkı sinyallerinin, nihai cevabın doğru mu yanlış mı olacağını kestirmede oldukça güçlü bir gösterge olduğunu ve doğruluk tahmininde yüksek AUROC skorları elde edilmesini sağladığını kanıtlamıştır [4].

Shapiro vd. tarafından sunulan "HALT: Hallucination Assessment via Log-probs as Time series" başlıklı çalışmada, dil modellerinin ürettiği yanıtların doğruluğunu (halüsinasyon içerip içermediğini) değerlendirmek için üretilen tokenlerin log-olasılıkları bir zaman serisi olarak ele alınmıştır. Çalışma, modelin gizli durumlarına (hidden states) veya harici bir bilgi doğrulama mekanizmasına ihtiyaç duymadan, yalnızca üretilen tokenlerin olasılık dizilimleri (top-20) üzerinden modelin kalibrasyon eğiliminin Gated Recurrent Unit (GRU) gibi hafif makine öğrenmesi algoritmalarıyla öğrenilebileceğini kanıtlamıştır. Bu yaklaşım, sadece çıktı anındaki olasılıklara odaklanarak zaman serisi dinamiklerinden öznitelik çıkarımı yapması yönüyle mevcut çalışmamıza benzerdir [5].

Dil modellerinin Chain-of-Thought süreçlerindeki belirsizlik dinamiklerini teşhis eden Zhao'nun çalışmasında ise, doğrudan GSM8K ve MATH veri setleri üzerinde akıl yürütme güvenilirliği ve doğruluk tahmini incelenmiştir. Araştırmacı, modelin güvenini tek bir özet skor ile ölçmek yerine, akıl yürütme adımları boyunca hesaplanan belirsizlik diziliminin "şeklinin" (örneğin sürekli azalan, monoton bir eğilim gösterip göstermediğinin) nihai cevabın doğruluğunu tahmin etmede çok daha güçlü bir gösterge olduğunu ortaya koymuştur. Çalışma, ayrıca token olasılıklarına dayalı kalibrasyonun üretim derinleştikçe bozulma eğiliminde olduğunu göstermiştir. Bu bağlamda, çalışmamızda GSM8K-TR veri seti üzerinde her token için anlık olarak toplanan olasılık

farkı sinyallerinin (top1-top2) üretim süreci boyunca nasıl evrildiğinin incelenmesi; matematikteki akıl yürütme problemlerinde doğru ve yanlış üretimleri birbirinden ayırmak için modelin "şekilsel" (trajectory) güven profilini çıkarma hipoteziyle de uyum içerisindedir [1].

III. MATERYAL VE YÖNTEM

A. Veri Seti ve Model

GSM8K (Grade School Math 8K) veri kümesinin train spliti kullanılarak 1200 soru için Cosmos T1 (Turkish-Gemma-9b-T1) modeli ile cevap üretilmiştir. Bu cevaplar: soru id'si, model tarafından üretilen cevap metni, top1-top2 skor listesi, tahmin sonucu (metnin en sonundaki sayısal değer), gerçek cevabın sayısal değeri ve üretilen cevabın doğruluğu (doğru veya yanlış) şeklinde 6 parametre ile pkl uzantılı dosya olarak kaydedilmiştir.

Bu işlem iş yükü nedeniyle iki ayrı seferde yapılmıştır. İlk önce 0-600 nolu sorular için kod çalıştırılmış, bu işlem 335.0 dk sürmüştür. Sonrasında ise 600-1200 nolu sorular için tekrar çalıştırılmış bu işlem 322.0 dk sürmüştür.

Colab ortamında A100 GPU ile çalışılmış ve top1-top2 skorları farkının hesaplandığı bu işlem sonucunda elde edilen 2 adet pkl dosyası yerel bilgisayara indirilmiştir.

İlk adımda model 10 örnek üzerinde: 216,512 ve 1024 token ile çalıştırılmış ve çıktılar incelenmiştir. Bunun sonucunda 10 cevabın doğruluğu sırasıyla %50, %60, %50 olarak hesaplanmıştır. Bu alt kümede en yüksek doğruluk 512 token ile elde edildiği için devamındaki kapsamlı deneyler (1200 soru) 512 token ile gerçekleştirilmiştir.

Devamında yalnızca 3 yöntem ile (LSTM, 1D-CNN, XG-Boost) accuracy, AUC ve f1 metrikleri ölçülmüştür. Bu deneyler çalışma genelinde kullanılan genel 1200 soruluk verisetinin ve thinking sürecini tamamen bitirmiş 210 soruluk alt kümenin üzerinde gerçekleştirilmiştir.

Sonraki deneyler için sorular 5 ayrı fold'a ayrılmıştır. 1200 soruluk verinin %90'ı train %10'u test olacak şekilde 5 fold'un her biri train ve test olarak ayrılmıştır. Her fold için gerçekleştirilen deneylerin ortalaması alınmıştır. Makine öğrenmesi algoritmalarına vermek için her fold verisine ait 50 öznitelikten oluşan csv dosyaları oluşturulmuştur. Baştaki üç yönteme beş yöntem daha eklenerek deneyler artırılmıştır.

B. Özellik Çıkarma

Bu çalışmada her soru için elde edilen değişken uzunluktaki top1-top2 fark dizisinden 50 özellik çıkarılmıştır. Özellikler 12 gruba ayrılmaktadır.

a) *Temel İstatistikler:* Dizinin genel güven düzeyini ve yayılımını özetleyen özelliklerdir. Ortalama (mean) ve ortanca (median), modelin üretim sürecindeki genel güven seviyesini temsil etmektedir. Standart sapma (std) ve değer aralığı (range), güvenin ne kadar dalgalandığını; çeyrekler arası aralık (IQR) ise aykırı değerlerden arındırılmış bir yayılım ölçüsü olarak bu dalgalanmayı daha sağlam biçimde temsil etmektedir.

b) *Yüzdelik Dilimler (Percentile'lar)*: Ortalama, dağılımın şeklini gizleyebilir. Örneğin, tokenların büyük çoğunluğu yüksek güvenle üretilirken yalnızca birkaçı çok düşük güvenle üretildiğinde ortalama yanıltıcı biçimde yüksek çıkabilir. Bu durumu yakalamak için p10, p25, p75 ve p90 yüzdelik dilimleri hesaplanmıştır. Bu hesaplama için token değerleri küçükten büyüğe sıralanır. Elde edilen bu değerlerden p10 değeri, en belirsiz %10'luk token grubunun bitiş değerini gösterirken; p90 değeri, en emin olunan (en yüksek güvene sahip) %10'luk grubun güven tabanını (başlangıç değerini) yansıtmaktadır. Böylece modelin cevabı üretirken yaşadığı en derin çöküşler (alt uç) ve ulaştığı maksimum kararlılık seviyeleri (üst uç) ayrı ayrı izlenebilmektedir.

c) *Üç Bölge Ortalaması*: Grünefeld et al. (2026) çalışmasından esinlenerek her dizi üç eşit bölgeye ayrılmış; ilk %25 (early), orta %50 (mid) ve son %25 (late) için ayrı ortalamalar hesaplanmıştır. Bu özellikler, modelin soruyu anlama (başlangıç), hesaplama (orta) ve sonuç yazma (son) aşamalarındaki güven düzeylerini birbirinden bağımsız olarak temsil etmektedir. Bölgeler arası farklar (early-mid, mid-late, early-late) ise güvenin üretim süreci boyunca nasıl evrildiğini göstermektedir.

d) *Slope, r^2 ve Intercept* : Token pozisyonları bağımsız değişken, top1-top2 fark değerleri bağımlı değişken olarak alınıp doğrusal regresyon uygulanmıştır. Elde edilen eğim (slope), güvenin üretim süreci boyunca genel yönünü ve hızını ifade etmektedir. Negatif bir slope, modelin ilerledikçe giderek daha emin hale geldiğine, yani belirsizliğin azaldığına işaret etmektedir. Grünefeld çalışmasında doğru cevap üretilen izlerde belirsizliğin yanlış cevaplara kıyasla daha dik ve daha düzenli biçimde azaldığını göstermiştir [3]. r^2 (Uyum kalitesi), bu doğrusal trendin ne kadar düzenli izlendiğini ölçmektedir. $r^2 = 1$, güvenin tamamen pürüzsüz ve doğrusal bir şekilde değiştiğini; $r^2 \approx 0$ ise değişimin rastgele ve düzensiz olduğunu göstermektedir. Doğru cevaplarda daha yüksek r^2 beklenmektedir; zira modelin tutarlı bir akıl yürütme izlediği durumlarda güven değişiminin de daha düzenli olması beklenmektedir. Intercept, modelin üretimin başında sahip olduğu başlangıç güvenini temsil etmekte olup slope ile birlikte yorumlanmaktadır. Son çeyrek eğimi (slope_late) ise yalnızca dizinin son %25'ine uygulanan regresyonun eğimidir. Genel slope tüm üretim sürecini özetlerken slope_late, modelin cevabı sonuçlandırırken güveninin nasıl değiştiğini ayrı olarak yakalamaktadır. Cevap yazma aşamasındaki güven değişiminin hata tespitinde özellikle bilgilendirici olduğu bilinmektedir.

e) *5. Ratio Metrikleri (Eşik Bazlı Oranlar)*: Güvenin belirli eşik değerlerinin altında ya da üzerinde kaldığı token oranları hesaplanmıştır. 0.1, 0.3, 0.5 ve 0.8 altındaki oranlar belirsiz token yoğunluğunu; 0.9 ve 0.99 üzerindeki oranlar ise modelin maksimum emin olduğu anların sıklığını ölçmektedir. Özellikle 0.5 eşiği, top1 ve top2 olasılıklarının neredeyse eşitlendiği, yani modelin fiilen rastgele seçim yaptığı durumları temsil etmesi bakımından önem taşımaktadır.

f) *Dip Analizi*: Jenerasyon sırasında güven skorunun aniden ve belirgin biçimde çakıldığı noktalar (dipler), mod-

elin o adımı üretirken ciddi bir kararsızlık yaşadığını göstermektedir. Modelin yaşadığı bu çöküşleri algoritmik olarak yakalayabilmek için güven sinyali matematiksel olarak tersine çevrilmiş ve sinyal işleme literatüründeki "peak detection" (tepe noktası bulma) algoritmaları bu ters sinyal üzerinde çalıştırılmıştır. Bu yöntemle üç temel öznelik çıkarılmıştır: modelin cevap boyunca kaç kez tereddüt ettiğini gösteren *toplam dip sayısı* (n_dips), bu tereddütlerin genel şiddetini yansıtan *ortalama dip derinliği* (mean_dip_depth) ve jenerasyon sırasındaki en büyük kafa karışıklığını yakalayan *maksimum dip derinliği* (max_dip_depth). Bir cevapta dip sayısının yüksek olması, modelin mantık zincirini kurarken sürekli sendelediğini; maksimum dip derinliğinin yüksek olması ise belirli bir adımda çok şiddetli bir bilgi eksikliği yaşadığını göstermekte olup, her iki durum da ulaşılan nihai sonucun hatalı olma ihtimalini güçlü bir şekilde artırmaktadır.

g) *İlk ve Son Token Bölgeleri*: İlk 10, ilk 50, son 10 ve son 50 token'ın ortalamaları ayrı ayrı hesaplanmıştır (first_10_mean, first_50_mean, last_10_mean, last_50_mean). Bu özellikler, early/late bölge ortalamalarına kıyasla daha dar pencereleri temsil etmekte; özellikle modelin üretimin hemen başında ve sonundaki güven durumunu hassas biçimde yansıtmaktadır. İlk ve son 10 token arasındaki fark (first_last_diff) ise üretim boyunca güvenin değişim yönünü özetlemektedir.

h) *Entropi Yaklaşımı ve Belirsizlik Analizi*: Dil modellerinin üretim sırasındaki belirsizliğini ölçmek için standart bir yöntem olan "tüm sözcük dağarcığı entropisi", modelin tam olasılık dağılımı mevcut olmadığından hesaplanamamıştır. Bu kısıtı aşmak amacıyla, modelin en güçlü iki tahmini (Top-1 ve Top-2) arasındaki olasılık farkı (Δ) baz alınarak, belirsizliği temsil eden ikili bir yaklaşım geliştirilmiştir. Bu yaklaşımda, modelin o anki kararı $p_1 \approx 0.5 + \frac{\Delta}{2}$ ve ikinci en güçlü aday ise $p_2 \approx 0.5 - \frac{\Delta}{2}$ olarak tanımlanmış; bu değerler üzerinden Shannon ikili entropi (*binary entropy*) formülü kullanılarak bir "yaklaşık entropi" (*approx_entropy*) sinyali üretilmiştir. Analizlerde kullanılan özellikler; bu yaklaşık entropi serisinin ortalaması, standart sapması, ilk çeyrek (p25) ve üçüncü çeyrek (p75) değerlerinden türetilmiştir (entropy_mean, entropy_std, entropy_early ve entropy_late).

i) *Dağılım Şekli (cv, skewness, kurtosis)*: Varyasyon katsayısı (CV = std/mean), standart sapmayı ortalamaya normalize ederek farklı güven seviyelerindeki dizileri karşılaştırılabilir kılmaktadır. Ortalama güveni yüksek ama std değeri aynı olan iki dizi, CV ile doğru şekilde ayrıştırılabilmektedir. Skewness (Çarpıklık), güven dağılımının simetrisini ölçmektedir. Negatif skewness, tokenların büyük çoğunluğunun yüksek güvenle üretildiği ancak nadir belirsizlik anlarının bulunduğu durumu; pozitif skewness ise büyük çoğunluğun belirsiz olduğu durumu temsil etmektedir. Kurtosis (Basıklık), dağılımın uç değer yoğunluğunu ölçmektedir. Yüksek kurtosis, tokenların büyük çoğunluğunun ya çok yüksek ya da çok düşük güvenle üretildiği iki kutuplu bir dağılıma; düşük kurtosis ise güven değerlerinin 0-1 aralığına dengeli biçimde yayıldığı düzleşik bir dağılıma işaret etmektedir.

j) *Otokorelasyon*: Lag-1 otokorelasyonu (autocorr_lag1), ardışık tokenların güven değerleri arasındaki korelasyonu ölçmektedir. Yüksek otokorelasyon, güvenin tokenden tokena az değiştiğini; düşük veya negatif otokorelasyon ise ani sıçramaların ve tutarsız geçişlerin olduğunu göstermektedir.

k) *Uzunluk ve Pozisyo*: length (Toplam token sayısı) ve length_normalized (toplam uzunluk/token kapasitesi-bu çalışma için 512-), modelin düşünme çabasını temsil eder. Uzunluk ile doğruluk arasındaki ilişki doğrusal değildir; cevapların aşırı kısa veya uzun olması hatalı üretimi tetikleyebilir. En düşük güvene sahip token'ın konumunu gösteren min_position parametresi ise belirsizliğin üretim sürecinin hangi aşamasında yoğunlaştığını göstermektedir.




Fig. 1. 50 özelliğinin doğruluk etiketiyle Pearson korelasyonu; erken dönem güven özellikleri

Grünefeld ve arkadaşları çalışmalarında üç farklı uncertainty ölçüsü üzerinden 5'er feature çıkarmışlardır [3]. Bu çalışmada ise yalnızca tek bir sinyal (top1-top2 farkı) mevcut olduğundan, bu sinyalin farklı boyutlarını kapsayan zengin bir feature seti oluşturulmuştur.

Şekil 1 de gösterilen korelasyon grafiği bahsedilen 50 özelliğin etkilerini göstermektedir. En üstte gözüken first_50_mean özelliği üretilen cevabın ilk 50 token'ındaki ortalama güven farkını temsil etmektedir. Yani modelin buradaki cevabını ne kadar güvenerek yazdığını gösterir. Model bu ilk 50 token da cevabına güveniyorsa cevabın doğru olma ihtimali artmaktadır. Bu %20'lik bir etkiyle en etkili özelliktir. Hemen altındaki first_10_mean aynı özelliğin 50 değil de 10 token için etkisini temsil etmektedir. Tam tersi yönde en altta -0.207 ile gösterilen length değeri ise en etkili üçüncü metriktir. Bu ise bize cevap uzadıkça yanlış olma ihtimalinin arttığını göstermektedir. (first_50_mean, first_10_mean) en güçlü pozitif, cevap uzunluğu ve erken entropi ise en güçlü negatif ilişkiyi sergilemektedir.

C. Makine Öğrenmesi ve Derin Öğrenme Yöntemleri

Çalışma genelinde makine öğrenmesi yöntemleri kullanılarak top1-top2 sinyali üzerinden sınıflandırma yapmak amaçlanmıştır. Bununla birlikte makine öğrenmesi yöntemlerinin yanında etkilerini görmek için birkaç adet de derin öğrenme yöntemi denenmiştir. Aşağıda kısaca bu yöntemlerden bahsedilmiştir.

a) *XGBoost*: XGBoost (eXtreme Gradient Boosting), karar ağaçlarını sıralı bir şekilde inşa eden ve her ağaçta bir önceki modelin hatalarını minimize etmeye odaklanan, oldukça optimize edilmiş bir gradient boosting kütüphanesidir. Özellikle yapılandırılmış verilerde yüksek tahmin gücü, regularizasyon desteği ile aşırı öğrenmeyi (overfitting) engellemesi ve hesaplama verimliliği nedeniyle tercih edilmiştir.

b) *Random Forest*: Random Forest, birden fazla karar ağacının tahminlerini "bagging" yöntemiyle birleştiren bir topluluk (ensemble) öğrenme algoritmasıdır. Veri setinden rastgele örneklemeler olarak inşa edilen çok sayıda ağaç sayesinde, aykırı değerlere karşı dayanıklıdır ve doğrusal olmayan ilişkileri başarıyla modelleyebilir.

c) *Gradient Boosting*: Gradient Boosting, zayıf öğrencileri (genellikle basit karar ağaçları) birleştirerek güçlü bir tahminleyici oluşturur. Kayıp fonksiyonunun gradyanı (türevi) üzerinde çalışarak, her iterasyonda modelin hatasını düşüren bir optimizasyon sürecini temel alır.

d) *Logistic Regression*: Lojistik Regresyon, girdiler ve hedef sınıf arasındaki ilişkiyi lojistik fonksiyon (sigmoid) kullanarak modellediğimiz temel bir doğrusal sınıflandırıcıdır. Çalışmada, diğer karmaşık modeller için bir "baseline" (temel performans referansı) oluşturmak amacıyla kullanılmıştır.

e) *SVM (RBF Kernel)*: Destek Vektör Makineleri (SVM), veriyi yüksek boyutlu uzaylarda hiper-düzlemlerle birbirinden ayırmaya odaklanır. RBF (Radial Basis Function) çekirdeği kullanılarak, verinin doğrusal olmayan karmaşık yapıları kavisli karar sınırları ile başarıyla sınıflandırılması amaçlanmıştır.

f) *MLP (Sinir Ağı)*: MLP (Çok Katmanlı Algılayıcı), giriş katmanı, iki gizli katman (64 ve 32 nöron) ve çıkış katmanından oluşan ileri beslemeli bir sinir ağı mimarisidir. Bu çalışmada elle tasarlanmış 50 öznitelik üzerinde çalışmakta olup öznitelikler arasındaki doğrusal olmayan ilişkileri öğrenme kapasitesi sayesinde lojistik regresyon gibi doğrusal yöntemlere kıyasla daha karmaşık karar sınırları oluşturabilmektedir. Teknik olarak bir sinir ağı mimarisi olmakla birlikte, ham dizi yerine çıkarılmış öznitelikler üzerinde çalıştığından bu çalışmada ML yöntemleri kapsamında değerlendirilmiştir.

g) *1D-CNN*: 1D-CNN (Bir Boyutlu Evrişimli Sinir Ağları), genellikle görüntü işleme için kullanılan CNN'lerin zaman serilerine (token pozisyonlarına) uyarlanmış halidir. Veri içerisindeki yerel paternleri ve "dip" veya "zıplama" gibi anlık değişimleri, filtreler yardımıyla etkili bir şekilde yakalayabilmektedir.

h) *LSTM*: LSTM (Uzun Kısa Süreli Bellek), zaman serisi verilerindeki uzun süreli bağımlılıkları öğrenmek için

tasarlanmış özel bir RNN (Yinelemeli Sinir Ağı) mimarisidir. Cevabın başındaki bir tokenın, cevabın sonundaki bir kararı nasıl etkilediğini modelin "belleğinde" tutabildiği için, üretim sürecindeki zamansal akışı modellemek amacıyla kullanılmıştır.

IV. DENEYLER VE SONUÇLAR

Elde edilen verinin yapısı ve öznitelikleri hakkında bilgi edinmek için detaylı bir özellik çıkarımı işlemi uygulanmıştır. Görsel 1 veriye ait özet bir genel bakış sağlamaktadır.

Buna göre cevabın ilk tokenlarındaki yüksek güven ve yüksek yüzdelik dilimlerdeki güven doğrulukla pozitif ilişkili; cevap uzunluğu, erken dönem entropi ve dip sayısı negatif ilişkilidir.

Bir diğer önemli bulgu ise Şekil 2’de sunulan pozisyonel güven profilleridir. Soldaki grafik, jenerasyon süreci boyunca normalize edilmiş token pozisyonlarına göre top1 ve top2 olasılıkları arasındaki ortalama farkın değişimini göstermektedir. Eğriler incelendiğinde, doğru yanıtların üretim sürecine daima daha yüksek bir başlangıç güveni ile (daha büyük top1-top2 farkı) başladığı açıkça görülmektedir. Bu durum, modelin başarılı olacağı problemlere ilk adımlarda çok daha kararlı yaklaştığına işaret etmektedir. Cevabın ortalarına gelindiğinde ise her iki eğri de yataya yaklaşmakta; model hem doğru hem de yanlış cevaplar için kararını netleştirmeye başlamaktadır. Son kısımlara doğru büyük bir dalgalanma yaşanmamakla birlikte, yanlış cevapların güven skorunun doğru cevapları az bir farkla da olsa geride bıraktığı görülmektedir.

Sağdaki grafik ise, soldaki grafikteki doğru ve yanlış cevap eğrilerinin noktasal farkını özetlemektedir. Farkın pozitif olması, modelin doğru cevaplarda daha emin olduğunu belirtir. Bu farklılık tablosunun geneli değerlendirildiğinde sürecin büyük bölümünde modelin doğru cevaplarda daha yüksek özgüvene sahip olduğu doğrulanmaktadır. Ancak cevabın orta bölümlerinde ve özellikle bitiş aşamasında (1.0 pozisyonu), durum tersine dönmekte ve modelin ürettiği yanlış cevapların arkasında yüksek bir 'sahte güven' ile durduğu (negatif barlar) tespit edilmektedir.

TABLE I
ML YÖNTEMLERİNİN VE GSM8K VERİ KÜMESİNİN FARKLI BOYUTLARI ÜZERİNDEKİ PERFORMANS KARŞILAŞTIRMASI

Yöntem	1200 Soru			210 Soru		
	accuracy	AUC	f1(macro)	accuracy	AUC	f1(macro)
LSTM	0.60	0.5944	0.60	0.50	0.7600	0.33
ID-CNN	0.58	0.5888	0.57	0.50	0.6400	0.33
XGBoost	0.54	0.5416	0.54	0.60	0.6429	0.58

GSM8K üzerinde yapılan deney sonuçlarında ytu-ce-cosmos/Turkish-Gemma-9b-T1 modeliyle %77.41 doğruluk elde edilmiştir [6]. Aynı veri setinden elde edilen 1200 soruluk alt kümede gerçekleştirilen deney sonuçları Tablo I’de verilmiştir. Deneylerde elde edilen doğruluk değerlerinin genel model performansına kıyasla düşük kalmasının temel sebebinin, 512 token sınırı nedeniyle üretilen cevapların büyük

çoğunluğunun sonuca ulaşılmadan kesilmesi ve bu durumun etiket kalitesini bozması olduğu düşünülmektedir.

Bu savı sınamak amacıyla, 1200 soruluk kümeden yalnızca kesintisiz cevap üretilebilen 210 soruluk alt küme ayrılmış ve deneyler tekrarlanmıştır. Tablo incelendiğinde, bu yeni kümede derin öğrenme modellerinin (LSTM, 1D-CNN) Doğruluk (Accuracy) değerlerinin %50 seviyesine düştüğü ve Macro-F1 skorlarının 0.33’te kaldığı görülmektedir.

210 soruluk oldukça küçük ve dengesiz (%76 Doğru, %24 Yanlış) bir veri setinde bu performans kaybı beklenen bir durumdur. Ancak, modelin ayırt edicilik gücünü eşik değerinden ve sınıf dengesizliğinden tamamen bağımsız olarak ölçen AUC (Eğri Altında Kalan Alan) skorları incelendiğinde görülen 0.17 puanlık artış modelin doğru ve yanlış yanıtlar arasındaki sinyali çok daha net yakaladığını göstermektedir.

Bunun yanında XGBoost modeli de hem Doğruluk hem de AUC bazında belirgin bir artış sergilemiştir.

Tablo I de yapılan deneylerden sonra daha model çeşitliliği artırılarak Tablo II, tüm modellerin her bir katmandaki (fold) performans dalgalanmalarını göstermektedir. Geleneksel makine öğrenmesi yöntemleri arasında yer alan *Lojistik Regresyon*, sadece ortalama AUC skorunda (0.70) ve ortalama accuracy skorunda (0.65) en yüksek başarıyı elde etmekle kalmamış, aynı zamanda standart sapmasının (± 0.01) minimum olmasıyla en kararlı model olduğunu kanıtlamıştır. Ağaç tabanlı yöntemler (XGBoost ve Random Forest) ortalama bazda başarılı olsalar da, Fold 2 ile Fold 3 arasında ciddi dalgalanmalar yaşamışlardır. Derin öğrenme tarafında ise modeller benzer accuracy skorları vermiştir. 1D-CNN özellikle 3. Fold’da 0.75 AUC skoruna ulaşarak tüm modeller arasında en yüksek AUC skoruna ulaşırken, LSTM bu metrikte 1D-CNN’in oldukça gerisinde (0.9 puan) kalmıştır.

Fold düzeyindeki performans incelemeleri, Fold 2’nin dört farklı model için en yüksek başarı metriklerine ulaşılan katman olduğunu göstermektedir. Buna karşılık Fold 4, hiçbir modelde en yüksek performansı sergileyememesi nedeniyle genel başarı ortalamasının en düşük olduğu fold olarak öne çıkmaktadır.

V. GELECEK ÇALIŞMALAR

Grunefeld’in çalışmasında yüksek skorlar elde etmek için yalnızca top-top2 farkı yerine modelin tokenlar için ürettiği diğer alternatif skorlar da hesaba katılarak değerlendirme için daha detaylı bir profil oluşturulmuştur [3]. Sonraki aşamalarda bunun gibi yalnızca top1-top2 farkı yerine daha fazla olasılık değerinin hesaba katıldığı karşılaştırmalı analizler yapmak hedeflenmektedir. Ayrıca cevabın token kapasitesini artırarak düşünme sürecini tamamiyle bitirmiş cevapların doğruluk ve auc üzerindeki etkisini ölçmek amaçlanmaktadır.

REFERENCES

- [1] X. Zhao, "Entropy trajectory shape predicts llm reasoning reliability: A diagnostic study of uncertainty dynamics in chain-of-thought," 2026. [Online]. Available: <https://arxiv.org/abs/2603.18940>
- [2] COSMOS AI Research Group and Yıldız Technical University, "GSM8K-TR: GSM8K Dataset Translated to Turkish," 2025, accessed: 2026-06-29. [Online]. Available: https://huggingface.co/datasets/ytu-ce-cosmos/gsm8k_tr

Pozisyonel Güven Profili — Doğru vs Yanlış




Fig. 2. Normalize token pozisyonuna göre doğru ve yanlış cevapların pozisyonel güven profili. Sol: ortalama $\pm$ standart sapma bantlarıyla top1-top2 güven farkının üretim süreci boyunca seyri. Sağ: doğru ve yanlış cevaplar arasındaki nokta bazlı güven farkı (pozitif değerler doğru cevapların daha emin olduğunu gösterir)

TABLE II
TÜM MODELLERİN 5-FOLD ÇAPRAZ DOĞRULAMA PERFORMANS SKORLARI (ACCURACY VE AUC)

Yöntem	Fold 1		Fold 2		Fold 3		Fold 4		Fold 5		Ortalama ($\pm$ SS)	
	Acc	AUC	Acc	AUC	Acc	AUC	Acc	AUC	Acc	AUC	Acc	AUC
XGBoost	0.62	0.67	0.70	0.74	0.56	0.63	0.58	0.65	0.63	0.70	0.62 (± 0.05)	0.68 (± 0.04)
Random Forest	0.60	0.66	0.64	0.73	0.63	0.69	0.59	0.65	0.62	0.71	0.62 (± 0.02)	0.69 (± 0.03)
Gradient Boosting	0.59	0.64	0.64	0.67	0.57	0.62	0.57	0.60	0.67	0.72	0.61 (± 0.04)	0.65 (± 0.04)
Logistic Regression	0.63	0.70	0.69	0.71	0.65	0.70	0.62	0.68	0.64	0.72	0.65 (± 0.03)	0.70 (± 0.01)
SVM (RBF Kernel)	0.67	0.72	0.63	0.70	0.65	0.68	0.55	0.63	0.59	0.65	0.62 (± 0.04)	0.68 (± 0.03)
MLP (Sinir Ağı)	0.63	0.63	0.73	0.73	0.58	0.62	0.56	0.60	0.52	0.58	0.60 (± 0.07)	0.63 (± 0.05)
1D-CNN	0.58	0.63	0.60	0.67	0.67	0.75	0.58	0.67	0.59	0.66	0.60 (± 0.03)	0.68 (± 0.04)
LSTM	0.59	0.50	0.60	0.56	0.63	0.62	0.59	0.60	0.68	0.66	0.62 (± 0.04)	0.59 (± 0.05)

- [3] N. Grünefeld, B. Højer, P. Mondorf, B. Plank, A. Rogers, C. Hardmeier, S. Heinrich, and J. Frellsen, “Tracing uncertainty in language model reasoning,” 2026. [Online]. Available: <https://arxiv.org/abs/2605.07776>
- [4] B. Plaut, N. X. Khanh, and T. Trinh, “Probabilities of chat llms are miscalibrated but still predict correctness on multiple-choice qa,” 2025. [Online]. Available: <https://arxiv.org/abs/2402.13213>
- [5] A. Shapiro, K. Taneja, and A. Goel, “Halt: Hallucination assessment via log-probs as time series,” 2026. [Online]. Available: <https://arxiv.org/abs/2602.02888>
- [6] COSMOS AI Research Group and Yıldız Technical University, “ytu-ce-cosmos/turkish-gemma-9b-t1,” 2025, hugging Face Model Card — Turkish reasoning-optimized Gemma-2 model. [Online]. Available: <https://huggingface.co/ytu-ce-cosmos/Turkish-Gemma-9b-T1>